

# **Wavelet-Guided Diffusion for Low- Light Image Enhancement**

Group 7

---

# Table of Contents

1  
Overview

2  
Baseline  
method

3  
Description  
of method

4  
Novelty

5  
Experimental  
results

6  
Ablation  
study

7  
Conclusion

# — Overview

- ① 使用 DiffLL 當作 Base model
- ② Test-time augmentation 的討論
- ③ Loss 與 wavelet 的討論

# **Baseline method**

JUNE 2023

# Low-Light Image Enhancement with Wavelet-based Diffusion Models

**HAI JIANG**, Sichuan University, Megvii Technology, China

**AO LUO**, Megvii Technology, China

**SONGCHEN HAN**, Sichuan University, China

**HAOQIANG FAN**, Megvii Technology, China

**SHUAICHENG LIU \***, University of Electronic Science and Technology of  
China, Megvii Technology, China



# Haar wavelets

$$\{A_{low}^1, V_{low}^1, H_{low}^1, D_{low}^1\} = 2D-DWT(I_{low})$$

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

- 無損變換
- A: 低頻細節 => Diffusion
- V, H, D: 高頻細節 => high-frequency restoration module (HFRM)

# — Haar wavelets

$$\{A_{low}^k, V_{low}^k, H_{low}^k, D_{low}^k\} = 2D-DWT(A_{low}^{k-1}),$$

- 對低頻作 K 次 Haar wavelets 變化
- 維度降低 => 加速訓練
- 保留所有高頻係數，以便重建

# Diffusion

*# Forward diffusion process*

$t \sim \text{Uniform}\{1, \dots, T\}$

$\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

Perform a single gradient descent step for  
 $\nabla_{\theta} \|\epsilon_t - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t, \tilde{\mathbf{x}}, t)\|^2$


GT 加噪，由 low-light 的低頻係數去引導學習

$\alpha_t$ : 原始訊號保留比例

$\epsilon$ : Noise



# HFRM



$$\hat{A}_{low}^{k-1} = 2D-IDWT(\{\hat{A}_{low}^k, \hat{V}_{low}^k, \hat{H}_{low}^k, \hat{D}_{low}^k\}),$$

# — LOSS

$$\mathcal{L}_{diff} = E_{\mathbf{x}_0, t, \epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|\epsilon_t - \epsilon_{\theta}(\mathbf{x}_t, \tilde{\mathbf{x}}, t)\|^2] + \|\hat{A}_{low}^K - A_{high}^K\|^2.$$

$$\begin{aligned} \mathcal{L}_{detail} = & \lambda_1 \sum_{k=1}^K \|\{\hat{V}_{low}^k, \hat{H}_{low}^k, \hat{H}_{low}^k\} - \{V_{high}^k, H_{high}^k, D_{high}^k\}\|^2 \\ & + \lambda_2 \sum_{k=1}^K \text{TV}(\{\hat{V}_{low}^k, \hat{H}_{low}^k, \hat{H}_{low}^k\}), \end{aligned}$$

$$\mathcal{L}_{content} = |\hat{I}_{low} - I_{high}|_1 + (1 - \text{SSIM}(\hat{I}_{low}, I_{high})).$$

# — Baseline problems

- Baseline Problems:
  - Output 仍包含小範圍雜訊或者色塊
  - Diffusion 可能無法完全消除noise
  - loss 沒有直接最佳化 LPIPS



# — Description of our method

- 先用base model訓練220epoch
- 使用消融實驗效果好者，進行改動



# — Novelty

pruning

MSE loss + LPIPS loss + SSIM loss

TTA

Two-level  
wavelet  
frequency

Wavelet Soft  
Thresholding

—  
**Novelty**

TTA

# Objective

- Diffusion model 在推論時可能產生微小噪點與局部偽影
- 我們測試 TTA 是否能透過多次變換與平均，讓輸出更穩定。

# Method

- 使用兩種 TTA：
  - 旋轉與翻轉
    - 將測試影像轉成原圖、水平翻轉、垂直翻轉、旋轉 90 度。
    - 分別輸入模型後，再反向變換回原位，最後取平均。



# Method

- 使用兩種 TTA：
  - Pixel Shifting
    - 將輸入影像做微小平移，例如： $(0,0)$ 、 $(+s,0)$ 、 $(-s,0)$ 、 $(0,+s)$ 、 $(0,-s)$ 。
    - 每個版本分別推論，再反向平移回原座標並取平均。

—  
**Novelty**

Architecture  
Modification

# Objective

- 低光影像中的雜訊不一定只出現在高頻。有些高 ISO 或熱雜訊會形成大範圍亮斑、色塊或低頻污染，這些成分可能會進入 LL 低頻空間。
- 如果 diffusion 直接在不夠乾淨的低頻表示上修復，模型可能把低頻雜訊也當成照明結構一起放大。

# Method

- 將原本的一階小波架構改成二階小波架構：
  - 對輸入影像做第一次 DWT，得到 LL1 與高頻成分
  - 再對 LL1 做第二次 DWT，得到更低頻的 LL2
  - 將 diffusion restoration 放在 LL2 上進行
  - 最後透過 inverse DWT 重建回影像空間



—  
**Novelty**

Loss  
Modification

# Objective

- MSE：約束像素誤差
- SSIM loss：約束影像結構
- LPIPS loss：約束感知品質

# —

## Method

- Baseline loss:
  - $L_{\text{photo}} = L1 + (1 - \text{SSIM})$
- Modified loss:
  - $L_{\text{photo}} = \text{MSE} + w_{\text{ssim}} \cdot (1 - \text{SSIM}) + w_{\text{lpips}} \cdot \text{LPIPS}$

—  
**Novelty**

Sample  
Selection



# Objective

- 部分 validation images 的 metrics 特別差，可能代表這些樣本更困難，或資料分布與一般樣本不同。
- 因此我們測試使用 better 50%、middle 50%、worse 50% 樣本訓練，觀察不同難度樣本對模型的影響。

## Method

- 在training時將資料分成：
  - Better 50%、middle 50%、Worse 50%分別是表現較好的50%、中間50%、較差的50%
- 接著分別測試：
  - 從 0 epoch 開始訓練
  - 從已收斂的 276 epoch checkpoint 開始 fine-tune

# — **Novelty**

Wavelet Soft  
Thresholding

# Objective

- 我們想測試在訓練前先對高頻成分去噪，是否能讓模型更容易學習乾淨的細節。
- 傳統小波去噪認為：
  - 高頻中的小幅度係數通常較可能是雜訊；
  - 大幅度係數通常較可能是真實邊緣。



## Method

- 在高頻子圖 LH / HL / HH 上使用 soft thresholding。
- 小於 threshold 的高頻值會被削弱或歸零
- 較大的高頻值則保留，用來保留主要邊緣與結構。

# Experimental results

|         |        |         |           |            |
|---------|--------|---------|-----------|------------|
| PSNR ↑  | SSIM ↑ | LPIPS ↓ | Size(M) ↓ | FLOPs(G) ↓ |
| 21.3335 | 0.6515 | 0.4393  | 22.079    | 43.9145    |

# — Experimental results

220epoch:

- Validation summary (1000 images) | PSNR: 21.1682, SSIM: 0.6327, LPIPS: 0.4626

改loss + 改arch 後，訓練47epoch：

- Validation summary (1000 images) | PSNR: 21.1845, SSIM: 0.6283, LPIPS: 0.3578

加上tta中的rotation和slip:

- Validation summary (1000 images) | PSNR: 21.2003, SSIM: 0.6298, LPIPS: 0.3653


加上pixel shifting的tta:

- Validation summary (1000 images) | PSNR: 21.3524, SSIM: 0.6376, LPIPS: 0.3639



# — Experimental results

**original**



**without tta**



**after tta**





# **Ablation study 1 - Loss calculation**


# Ablation study 1 - Loss calculation

ORIGINAL version :

$L1 + (1 - SSIM)$

OUR version :

$MSE + (1 - SSIM) + LPIPS$




# Ablation study 1 - Loss calculation

ORIGINAL version :

$L1 + (1 - SSIM)$

OUR version :

$MSE + (1 - SSIM) + LPIPS$






# Ablation study 1 - Loss calculation

ORIGINAL version :

$L1 + (1 - SSIM)$

OUR version :

$MSE + (1 - SSIM) + LPIPS$





# **Ablation study 2 - Test-Time Augmentation**

# Ablation study 2 - TTA

旋轉和翻轉 + pixel shifting

## Validation summary (1000 images)

沒tta :

---

PSNR : 21.1850

SSIM : 0.6282

LPIPS : 0.3579

tta :

---

PSNR: 21.3524 → better

SSIM: 0.6376 → better

LPIPS: 0.3639 → worser !!

# Ablation study 2 - TTA

旋轉和翻轉 + pixel shifting

**why?**

- 旋轉和翻轉 => 破解神經網絡的「位置偏誤 (Translation Invariance Deficit)」
- pixel shifting => 空間過採樣 (Spatial Over-sampling) 與子像素融合

**It's GOOD but can be better.**

# **Ablation study 3 - pruning (unused)**




# **Ablation study results 3 - pruning (unused)**

## **why we use this?**


- 原因:  
看到有些圖片的metrics很爛，可能是某些類型圖片是訓練樣本太少或是有受汙染的圖片在訓練集中。
- 作法:  
分別測試從零開始訓練和從276(已經收斂)的model開始訓練，分別訓練七個epoch

# Ablation study results 3 - pruning (unused)


Validation PSNR (Higher is Better)



Validation SSIM (Higher is Better)




Validation LPIPS (Lower is Better)






# Ablation study results 3- pruning (unused)


PSNR (Higher is better)



SSIM (Higher is better)




LPIPS (Lower is better)




# **Ablation study 4 - Wavelet Soft Thresholding**




# Ablation study 4 - Wavelet Soft Thresholding



# Ablation study 4 - Wavelet Soft Thresholding



# Ablation study 4 - Wavelet Soft Thresholding



# Ablation study 4 – Wavelet Soft Thresholding

這個 Wavelet Soft Thresholding 並沒有帶來明顯提升  
**為什麼可能沒有效果？**

影像復原（去雨、去霧、去噪等類型）時，小波高頻部分包含：真實邊緣 / 細節紋理 / 雜訊

Soft Threshold 會同時削弱：細小雜訊 / 細小紋理 / 弱邊緣

因此網路收到的高頻資訊變少。對傳統小波去噪來說這是優點，但對這個model 而言，本身已經有能力學習哪些高頻是雜訊、哪些是有用特徵。所以先做 threshold 反而可能把有價值的訊號刪掉。



# — Conclusion

- TTA很適合解決diffusion model 生成後的噪點問題
- 只保留適度的低頻的細節對圖像的重建更佳
- pruning還要再調參，才可確認是否有益
- Wavelet Soft Thresholding不試用於此

# The End

THANK YOU FOR LISTENING